

Goldpreis-Prognose: Projektbericht Noel Ciborro Fernandez

Chronologische Zusammenfassung der Arbeiten an dem Support Vector Regression. Trainingsbasis war zunächst (Kaggle, 2011–2018 bzw. 2019 über die Yahoo-Finance-API), im späteren Verlauf wurde auf das im Team abgestimmte, vorverarbeitete Format `gold_train_pp.csv` / `gold_test_pp.csv` umgestellt.

Phase 1: Aufbau der SVR-Pipeline

Den Ausgangspunkt bildete eine SVR mit RBF-Kernel, eingebettet in eine sklearn-Pipeline aus `SimpleImputer`, `StandardScaler` und `PCA` (`n_components=0.95`). Anders als bei den linearen Modellen im Team wurde nicht der absolute Goldpreis als Ziel verwendet, sondern die Preisänderung (`target_return = zukünftiger Preis - aktueller Preis`), gekapselt über einen `TransformedTargetRegressor` mit eigenem `StandardScaler` für die Zielgröße. Nach der Vorhersage wird der aktuelle Preis wieder addiert, um den absoluten Preis zurückzurechnen. Der Grundgedanke: Das Modell soll echte Kursbewegungen lernen, statt lediglich den letzten bekannten Preis zu wiederholen.

Für alle drei Horizonte (1, 5, 30 Tage) wurde je ein eigenes Modell trainiert (kein rekursiver Ansatz), mit Horizont abhängigem `gap` in `TimeSeriesSplit` (`n_splits=3`, `test_size=250`, `gap=h`), damit kein Trainings-Sample am Rand eines Folds ein Ziel besitzt, das in den Validierungsbereich hineinreicht. Die Hyperparameter `C`, `epsilon` und `gamma` wurden per `GridSearchCV` über den selben `TimeSeriesSplit` bestimmt.

Als Lag-Features werden für jede der zwölf Preisspalten drei Vergangenheitswerte verwendet (1, 5 und 30 Handelstage) - ein Kompromiss zwischen kurzfristiger, mittlerer und langfristiger Historie, passend zu den drei Prognosehorizonten, allerdings ohne Horizont spezifische Anpassung.

Phase 2: Data-Leak-Prüfung und Umstellung auf das Team-Datenformat

Die Umstellung auf vorverarbeitete Zielspalten (`Target_Adj_Close`, `Target_Adj_5d`, `Target_Adj_30d` aus dem gemeinsamen Preprocessing) machte eine erneute Prüfung auf Data Leakage notwendig, da eine falsch zugeordnete oder unvollständig entfernte Zielspalte in den Features ein schneller Fehler bei diesem Datensatz ist.

Das Team hat sich auf einen Code geeinigt, der zwei Prüfmechanismen enthält: ein `Assert`, der sicherstellt, dass keine `Target_Spalte` in `X_train` oder `X_test` verbleibt (alle `Target`-Spalten werden pro Horizont vollständig aus den Features entfernt, nicht nur die aktuell verwendete), sowie ein Abgleich, dass Trainings- und Testdaten exakt die selben Feature-Spalten besitzen. Ergänzt wurde ein Überlappungs-Check zwischen den Datumsbereichen von Train und Test, da genau diese Überlappung beim herbeiziehen externer Daten ein Problem sein kann. Der Check bestätigte für die verwendeten CSVs eine saubere Trennung.

Phase 3: Cross-Validation vor/nach Grid-Search und Ergebnis-Interpretation

Um den Effekt der Parameter-Suche sichtbar zu machen, wurde der Cross-Val-Score basierend auf RMSE des unoptimierten Modells mit dem Score des besten gefundenen Parametersatzes gegenübergestellt:

Horizont	CV-RMSE vorher	CV-RMSE nachher	Verbesserung
1d	0.9739	0.9655	+0.0084 (+0.9 %)
5d	2.2061	2.1620	+0.0440 (+2.0 %)
30d	7.7250	5.7196	+2.0054 (+26.0 %)

Die Verbesserung durch Grid-Search fällt mit steigendem Horizont deutlich größer, wobei bei 30 Tagen auch die Streuung zwischen den drei Folds vor der Suche sehr groß war, ein Hinweis darauf, dass eine einzelne Marktphase im Trainingszeitraum den Score dominiert und die Schätzung mit nur drei Folds entsprechend unsicher ist.

Die Testergebnisse auf dem Jahr 2019 im Vergleich zur naiven Baseline (Vorhersage = aktueller Preis):

Horizont	MAE	RMSE	R ²	Naiv-MAE	Naiv-RMSE
1d	0.77	1.02	0.9861	0.77	1.02
5d	1.62	2.22	0.9335	1.66	2.24
30d	4.39	5.87	0.5209	4.32	5.61

1-Tage-Horizont: MAE und RMSE des Modells sind identisch mit der naiven Baseline (0,77 / 1,02). Das SVR-Modell hat für diesen Horizont im Wesentlichen die Persistenzannahme reproduziert und liefert keinen erkennbaren Mehrwert gegenüber „der Preis morgen entspricht dem Preis heute“.

5-Tage-Horizont: Das Modell schlägt die Baseline leicht (MAE 1,62 vs. 1,66; RMSE 2,22 vs. 2,24), ein Vorsprung von rund 2–2,5 %. Spürbar, aber gering.

30-Tage-Horizont: Trotz R² von 0,52 liegt das Modell hinter der Baseline zurück (MAE 4,39 vs. 4,32; RMSE 5,87 vs. 5,61). Der Residuen-Plot zeigt keinen zufälligen Fehler, sondern einen klaren systematischen Bias: von etwa März bis August 2019 überwiegend positive Residuen, danach überwiegend negative. Das Modell hinkt der eigentlichen Trendbewegung hinterher, statt sie vorherzusagen. Das ist ein Problem, wenn ein Modell auf einen Zeitraum mit anderer Marktdynamik trainiert wurde, als es später bewerten muss.

Zusammengefasst zeigt sich ein für Finanzzeitreihen typisches Muster: Je kürzer der Horizont, desto mehr verhält sich das SVR-Modell wie die naive Baseline (weil kurzfristige Kursänderungen überwiegend Rauschen sind); je länger der Horizont, desto mehr driftet die Vorhersage vom echten Verlauf ab, ohne die Baseline tatsächlich zu schlagen. Nur beim 5-Tage-Horizont ergibt sich ein nachweisbarer, wenn auch kleiner Mehrwert.

Lessons Learned

Ein identischer Score zur Baseline ist selbst ein Ergebnis. Dass MAE und RMSE beim 1-Tage-Horizont exakt mit der naiven Baseline übereinstimmen, wirkt zunächst wie ein Zufall, ist aber die erwartbare Konsequenz eines return-basierten Ziels bei sehr kurzfristigen, stark verrauschten Kursänderungen. Ein Modell, das den Score der Baseline nur repliziert statt schlägt, ist kein Fehlschlag der Pipeline, sondern eine ehrliche Aussage über den Informationsgehalt der Features auf dieser Zeitskala.

Cross-Val-Score und Test-Score sind zwei verschiedene Fragen. Der CV-RMSE misst, wie gut das Modell innerhalb der Trainingsperiode über mehrere chronologische Folds verallgemeinert. Der Test-Score misst die Leistung auf einem völlig neuen Jahr (2019). Eine große Lücke zwischen beiden, wie beim 30-Tage-Horizont sichtbar. Das scheint ein Hinweis auf eine veränderte Marktdynamik zwischen Trainings- und Testzeitraum zu sein.

Data-Leak-Checks müssen bei jeder Datenformat-Änderung neu gedacht werden. Die vorverarbeiteten Team-CSVs hätte fast stillschweigend alle Target-Spalten für andere Horizonte als Features durchgelassen. Erst die explizite Übernahme der Assert-Checks hat das strukturell ausgeschlossen, statt sich auf Sorgfalt beim Spalten entfernen zu verlassen.

Mit nur drei CV-Folds sind Verbesserungsangaben in Prozent mit Vorsicht zu lesen. Da nur drei CV-Folds verwendet wurden, sollten die prozentualen Verbesserungen vorsichtig bewertet werden. Die großen Unterschiede zwischen den Fold-Scores beim 30-Tage-Horizont zeigen, dass einzelne Ergebnisse zufällig besser ausgefallen sein könnten.

Residuen-Plots zeigen Bias, den Metriken allein verstecken. MAE und RMSE machen das nicht sichtbar. Erst die zeitliche Darstellung der Residuen machte deutlich, dass die Fehler beim 30-Tage-Horizont nicht zufällig auftreten, sondern über mehrere Monate in dieselbe Richtung gehen.

Persönliche Reflexion

Größte Leistung. Die saubere Trennung zwischen Rückgabewert-Ziel und rekonstruiertem Preis in der TransformedTargetRegressor-Pipeline, kombiniert mit den Data-Leak-Checks beim Wechsel auf das Team-Datenformat. Dadurch ließ sich mit vertretbarem Aufwand umstellen, ohne die Sauberkeit (keine Zukunftsdaten in den Features, keine Überlappung zwischen Train und Test) zu verlieren.

Was war leicht, was war schwer. Leicht fiel der technische Pipeline-Aufbau: Imputer, Scaler, PCA und TransformedTargetRegressor sind bekannte sklearn-Bausteine, die sich zügig zusammenstecken ließen. Schwer war die Einordnung der Ergebnisse, insbesondere zu akzeptieren, dass ein exakt mit der Baseline übereinstimmender Score beim 1-Tage-Horizont kein Bug, sondern das plausibelste Ergebnis für diesen Zeithorizont ist, statt weiter an Parametern zu drehen, in der Hoffnung auf einen deutlicheren Vorsprung.

Habe ich etwas hinzugelernt. Ja: den Unterschied zwischen Cross-Val-Score (Trainingsperiode, mehrere Folds) und Test-Score sauber zu trennen und beide Zahlen als sich ergänzende Ergebnisse

zu lesen. Außerdem, wie stark bei wenigen CV-Folds die Streuung einzelner Folds „Verbesserungen“ verzerren kann.

Was ich wieder so machen würde. Die return-basierte Zielgröße statt absoluter Preis-Prognose, weil sie das Modell zwingt, tatsächliche Bewegungen statt nur das Preisniveau zu lernen. Ebenso den direkten Vorhersage-Ansatz mit einem eigenen Modell pro Horizont statt eines rekursiven Verfahrens, um dessen Fehler von vornherein auszuschließen.

Was ich anders machen würde. Die Lag-Liste Horizont spezifisch statt einheitlich für alle drei Modelle wählen (z. B. kürzere Zeiträume aus der Vergangenheit für den 1-Tage-, längere für den 30-Tage-Horizont), um zu prüfen, ob sich der Rückstand gegenüber der Baseline beim 30-Tage-Horizont dadurch verringern lässt. Außerdem die Anzahl der CV-Folds erhöhen oder zumindest die Fold-Streuung standardmäßig mit ausgeben, um „Verbesserung durch GridSearch“ nicht auf Basis eines einzelnen instabilen Folds zu überschätzen.